

电力系统优化：研究生入门

GPT 5.5, 何鹏飞

May, 2026

目录

1	Fifty Years of Power System Optimization	4
1.1	缩略语与符号表	4
1.2	文章核心内容概述	5
1.3	引言：研究背景与分析框架	5
1.3.1	研究背景	5
1.3.2	五类核心问题	5
1.3.3	方法演进路线	5
1.4	早期阶段：1970–1990 年的集中式框架	6
1.4.1	投资问题	6
1.4.2	运行规划问题	6
1.4.3	运行问题	6
1.4.4	控制与预测问题	6
1.5	近期阶段：1990 年至今的市场化与去中心化框架	7
1.5.1	投资问题	7
1.5.2	运行规划问题	7
1.5.3	运行问题	7
1.5.4	控制与预测问题	7
1.6	未来研究方向	8
1.7	小结	8
2	Power Flow Model	8
2.1	符号表	8
2.2	Bus Injection Model: 节点注入形式的交流潮流	9
2.3	节点类型: Slack、PQ 与 PV	9
2.4	DC Power Flow: 直流潮流近似	10
2.5	Branch Flow Model: 支路潮流模型及线性化	10
2.6	OPF-BFM 及 SOCP 松弛	11
2.7	不同潮流模型在优化中的选择	12

3	Deterministic Optimization	13
3.1	Economic Dispatch: 经济调度	13
3.1.1	无网络约束的单时段 ED	13
3.1.2	考虑网络约束的 DC-ED	14
3.2	Unit Commitment: 机组组合	14
3.2.1	确定性 UC 的目标函数	15
3.2.2	启停逻辑约束	15
3.2.3	最小开机与最小停机时间	15
3.2.4	出力上下限与爬坡约束	15
3.2.5	功率平衡与网络约束	16
3.3	ED 与 UC 的关系	16
3.4	小结	16
4	Optimization Under Uncertainty: Robust Optimization	17
4.1	符号约定与一般建模思路	17
4.2	静态鲁棒优化 (Static Robust Optimization)	18
4.2.1	基本思想: 一个固定决策应对所有场景	18
4.2.2	约束分解性质与凸包性质	18
4.2.3	鲁棒约束与最坏情形重构	19
4.2.4	静态 RO 的建模特点	20
4.3	可调鲁棒优化 (Adjustable Robust Optimization, ARO)	21
4.3.1	先行决策与等待观察决策	21
4.3.2	ARO 中的成本准则	21
4.3.3	仿射决策规则近似	22
4.3.4	完全可调模型与 CCG 算法	22
4.3.5	ARO 的建模特点	23
4.4	分布鲁棒优化 (Distributionally Robust Optimization, DRO)	23
4.4.1	从不确定取值到不确定分布	23
4.4.2	矩信息歧义集	23
4.4.3	鲁棒机会约束	24
4.4.4	最坏情形 CVaR 约束	24
4.4.5	可调分布鲁棒优化	24
4.4.6	DRO 的建模特点	25
4.5	数据驱动鲁棒随机规划 (Data-Driven Robust Stochastic Program)	25
4.5.1	为什么需要数据驱动?	25
4.5.2	基于散度的歧义集	26
4.5.3	鲁棒机会约束随机规划	26
4.5.4	与随机规划和鲁棒优化的关系	26
4.6	面向电力系统优化的统一视角	27
4.7	小结	27

5	Bilevel Programs	28
5.1	缩略语与符号表	28
5.2	基本思想：从顺序决策到双层规划	28
5.3	凸下层问题与 KKT 单层等价	29
5.4	为什么双层规划难求解	30
5.4.1	非凸可行域	30
5.4.2	约束规范条件失效	30
5.5	MPCC 的常用处理方法	31
5.5.1	正则化方法	31
5.5.2	惩罚方法	31
5.5.3	平滑方法	31
5.5.4	Big-M 线性化方法	32
5.6	线性双层规划	32
5.7	Linear Max-Min Problem	33
5.8	市场模型中的双层结构	33
5.8.1	零售市场问题	34
5.8.2	批发市场问题	34
5.9	Bilevel Mixed-Integer Program	35
5.10	与电力系统优化的联系	36
5.11	小结	36
6	参考文献	37

1 Fifty Years of Power System Optimization

本节整理综述文章“Fifty Years of Power Systems Optimization”的主要内容。该文回顾了电力系统优化在过去约五十年中的演进过程，核心线索是：电力系统从传统集中式规划与调度，逐步发展到市场化、去中心化和高比例可再生能源参与的新阶段；与此同时，运筹优化方法也从早期的线性规划、动态规划，发展到随机优化、鲁棒优化、均衡模型和凸松弛等复杂方法。

1.1 缩略语与符号表

缩略语	英文全称	中文含义
OR	Operations Research	运筹学
LP	Linear Programming	线性规划
MILP	Mixed-Integer Linear Programming	混合整数线性规划
MINLP	Mixed-Integer Nonlinear Programming	混合整数非线性规划
NLP	Nonlinear Programming	非线性规划
DP	Dynamic Programming	动态规划
SP	Stochastic Programming	随机规划
RO	Robust Optimization	鲁棒优化
MPEC	Mathematical Program with Equilibrium Constraints	均衡约束数学规划
EPEC	Equilibrium Problem with Equilibrium Constraints	含均衡约束的均衡问题
SOCP	Second-Order Cone Programming	二阶锥规划
SDP	Semidefinite Programming / Stochastic Dynamic Programming	半定规划 / 随机动态规划
SDDP	Stochastic Dual Dynamic Programming	随机对偶动态规划
GEP	Generation Expansion Planning	发电扩建规划
TEP	Transmission Expansion Planning	输电扩建规划
DEP	Distribution Expansion Planning	配电扩建规划
HTSP	Hydro-Thermal Scheduling Problem	水火电调度问题
OPF	Optimal Power Flow	最优潮流
ED	Economic Dispatch	经济调度
UC	Unit Commitment	机组组合
SCUC	Security-Constrained Unit Commitment	安全约束机组组合
WLS	Weighted Least Squares	加权最小二乘法
ARIMA	AutoRegressive Integrated Moving Average	自回归积分滑动平均模型

SVM	Support Vector Machine	支持向量机
ANN	Artificial Neural Network	人工神经网络
CVaR	Conditional Value-at-Risk	条件风险价值

1.2 文章核心内容概述

该综述将电力系统优化的发展划分为两个主要阶段：

- **1970–1990 年：集中式框架阶段。**该阶段的电力系统主要由单一主体进行规划和调度，优化目标通常是系统成本最小化。由于计算能力有限，模型多以确定性、线性或近似线性形式为主。
- **1990 年至今：去中心化/市场化框架与集中式框架并存阶段。**随着电力市场改革、可再生能源并网和多主体参与，系统优化目标从单一成本最小化扩展到社会福利最大化、风险管理、市场均衡和多主体策略行为分析。

文章围绕五类核心问题展开：投资、运行规划、运行、控制和预测。这五类问题覆盖了从多年尺度的容量规划，到实时尺度的控制决策，是理解电力系统优化全貌的基本框架。

1.3 引言：研究背景与分析框架

1.3.1 研究背景

运筹学是电力系统优化的重要理论基础。早期电力系统问题常用线性规划、动态规划和混合整数规划求解；随着系统规模扩大、市场机制引入和可再生能源接入，不确定性、非凸性和多主体博弈逐渐成为关键挑战。

简而言之，电力系统优化的发展不是单纯的算法演进，而是由电力系统运行机制变化推动的：系统越复杂，优化模型也越复杂。

1.3.2 五类核心问题

- **投资 (Investment)：**主要研究发电、输电、配电等长期容量建设问题，时间尺度通常为年到多年。
- **运行规划 (Operation Planning)：**关注中期运行安排，例如燃料采购、检修计划、水火电协调调度等。
- **运行 (Operations)：**面向短期运行决策，例如经济调度、机组组合、市场出清和最优潮流。
- **控制 (Control)：**面向实时或近实时控制，核心目标是维持系统频率、电压和动态稳定性。
- **预测 (Forecasting)：**为规划、运行和控制提供输入，包括负荷预测、电价预测、风电和光伏出力预测等。

1.3.3 方法演进路线

早期方法以 LP、MILP 和 DP 为主，适合确定性、集中式和规模相对有限的问题。近期方法则更加关注不确定性、非凸性和多主体行为，典型方法包括 SP、RO、MPEC、EPEC、SOC、SDP 和机器学习方法。

1.4 早期阶段：1970–1990 年的集中式框架

早期阶段的基本特征

- 电力系统由单一主体统一规划和调度。
- 优化目标通常是总成本最小化。
- 不确定性相对较弱，确定性模型占主导。
- 受计算能力限制，模型需要较强的线性化和简化。

1.4.1 投资问题

早期投资问题主要包括发电扩建规划、输电扩建规划和配电扩建规划。

发电扩建规划通常研究何时建设、建设多少以及建设何种类型的发电机组。早期模型从 LP 逐步发展到 MILP，并开始使用 Benders 分解和动态规划等方法。

输电扩建规划主要研究线路建设和网络结构增强。由于交流潮流模型较复杂，早期研究常采用直流潮流近似，并结合 MILP、Benders 分解和启发式算法求解。

配电扩建规划则更关注配电网络结构、容量扩展和供电可靠性，常用 MILP、网络流模型和分支定界法等方法。

1.4.2 运行规划问题

运行规划处于长期投资和短期运行之间，典型问题包括燃料采购、机组检修和水火电调度。

燃料采购问题常用 LP 或 MILP 建模，用于确定燃料购买量、库存和运输安排。机组检修问题需要在满足可靠性要求的同时安排检修时间，常采用 MILP、动态规划、Benders 分解和拉格朗日松弛。

水火电调度问题具有明显的跨时段耦合特征，因为水库当前放水会影响未来可用水量。早期研究常使用 NLP、多阶段模型和随机动态规划处理水文不确定性。

1.4.3 运行问题

运行问题直接服务于短期调度和系统运行。典型问题包括最优潮流、经济调度和机组组合。

最优潮流问题用于在满足电网物理约束的条件下优化发电出力、电压和潮流分布。由于交流潮流方程具有非线性和非凸性，早期主要使用 NLP、梯度法、牛顿法和内点法。

经济调度问题通常在已知开机状态下分配各机组出力。若成本函数为线性形式，可用 LP；若为二次成本函数，则通常形成 NLP。

机组组合问题需要决定机组启停状态和出力水平，因此天然具有整数变量，常用 MILP、优先顺序法、动态规划、拉格朗日松弛和 Benders 分解求解。

1.4.4 控制与预测问题

早期控制问题主要包括频率控制、无功控制和状态估计。状态估计通常建模为 NLP，并使用加权最小二乘法求解。

预测方面，主要对象是负荷和燃料价格。常用方法包括时间序列分析、ARIMA 模型和回归分析。

1.5 近期阶段：1990 年至今的市场化与去中心化框架

近期阶段的基本特征

- 电力市场改革使多主体参与成为常态。
- 优化目标从成本最小化扩展到社会福利、收益和风险协调。
- 可再生能源引入了更强的不确定性和波动性。
- 均衡模型、随机优化、鲁棒优化和凸松弛方法得到广泛应用。

1.5.1 投资问题

在市场环境下，发电投资不再只是集中式规划问题，而是受到市场价格、竞争策略和投资主体行为影响。此类问题常建模为双层规划、MPEC 或 EPEC，用于描述投资者与市场出清之间的相互作用。

输配电投资在很多情况下仍由系统运营商或监管机构进行集中式规划，但需要考虑与发电投资、电力市场和可靠性要求的协调。因此，MILP 和 MINLP 仍是重要建模工具。

1.5.2 运行规划问题

市场环境下的运行规划不仅要考虑物理可行性，还要考虑价格风险和市场收益。

检修规划需要协调发电企业与系统运营商之间的利益关系，因此可能形成 MILP 或 EPEC 模型。购电与市场参与策略则需要对冲现货市场价格波动风险，常采用随机规划和 CVaR 等风险度量。

水火电调度方面，SDDP 成为处理大规模、多阶段随机问题的重要方法，并被扩展到风险厌恶、整数变量和多机组场景。

1.5.3 运行问题

市场出清和机组组合成为近期运行优化中的核心问题。不同地区市场机制存在差异：欧洲市场更强调基于输电约束的市场出清，美国市场则更多采用基于 UC 的集中出清机制。

随着可再生能源不确定性增强，随机 UC 和安全约束机组组合成为重要研究方向。对于 OPF 问题，SOCP 和 SDP 等凸松弛方法被用于缓解交流潮流模型的非凸求解困难。

1.5.4 控制与预测问题

在高比例可再生能源系统中，变流器接口设备大量接入，使系统惯量、频率响应和动态稳定性发生变化。因此，控制问题更加关注分布式状态估计、快速控制和基于凸松弛的估计方法。

预测问题也从传统负荷预测扩展到电价、风电、光伏和多能源出力预测。机器学习方法，如 SVM、ANN 和深度学习，已经成为重要工具。

1.6 未来研究方向

未来值得关注的方向

- 非凸性**：交流潮流、机组物理约束和市场均衡模型通常具有非凸结构，如何高效求解仍是核心问题。
- 去中心化**：未来系统中主体更多、信息更分散，需要设计高效的分布式优化算法和协调机制。
- 市场设计**：电力市场需要解决容量补偿、灵活性激励和“缺失的资金”等问题。
- 不确定性管理**：风电、光伏、负荷和电价都具有不确定性，需要结合随机优化和鲁棒优化方法进行建模。
- 部门耦合**：电力系统将与交通、供热、氢能、工业等系统深度耦合，需要跨部门协同优化。
- 大规模与长时间跨度问题**：高比例新能源系统需要同时处理大规模空间网络和长时间尺度决策，因此高效分解算法和近似算法非常重要。

1.7 小结

这篇综述的核心贡献在于系统梳理了电力系统优化从集中式框架到市场化、去中心化框架的演进过程。其主线可以概括为：电力系统运行机制不断变化，推动优化模型从确定性、线性、集中式模型，逐渐发展到随机、鲁棒、均衡、分布式和数据驱动模型。

对于电力系统优化研究而言，运筹学方法始终是关键工具。未来，随着新能源、电力电子、储能、需求响应和多能源系统的发展，电力系统优化仍将是连接数学优化理论与能源工程应用的重要研究前沿。

2 Power Flow Model

本节介绍电力系统优化中最基础的网络约束：**潮流模型** (power flow model)。潮流模型用于描述在给定负荷与发电注入条件下，节点电压、线路电流和线路功率之间的稳态关系。对于优化问题而言，它的作用是把“电气物理规律”嵌入调度、规划和市场出清模型中。

在电力系统优化中，潮流模型通常有两类用途：一类是精确描述交流系统物理规律的 **AC power flow** (交流潮流)；另一类是为大规模优化提供计算效率的线性近似，例如 **DC power flow** (直流潮流近似) 和 **linearized branch flow model** (线性化支路潮流模型)。

2.1 符号表

符号	含义
$\mathcal{N}$	节点集合, $i, j \in \mathcal{N}$ 表示母线节点
$\mathcal{L}$	支路集合, $(i, j) \in \mathcal{L}$ 表示从节点 i 到节点 j 的线路
$\dot{V}_i$	节点 i 的复电压, $\dot{V}_i = e_i + jf_i$
V_i, θ_i	节点 i 的电压幅值和相角
$Y = G + jB$	节点导纳矩阵, G 和 B 分别为电导矩阵和电纳矩阵

p_i^g, q_i^g	节点 i 的有功、无功发电功率
p_i^d, q_i^d	节点 i 的有功、无功负荷功率
P_i^N, Q_i^N	节点 i 的净有功、净无功注入, $P_i^N = p_i^g - p_i^d$, $Q_i^N = q_i^g - q_i^d$
P_{ij}, Q_{ij}	线路 (i, j) 上的有功、无功潮流
r_{ij}, x_{ij}	线路 (i, j) 的电阻和电抗
$S_{ij}^{\max}$	线路 (i, j) 的视在功率容量上限

2.2 Bus Injection Model: 节点注入形式的交流潮流

Bus Injection Model (节点注入模型, BIM) 从节点复电压和节点注入功率出发建立潮流方程。设节点电压向量为

$$\dot{\mathbf{V}} = \mathbf{e} + \mathbf{j}\mathbf{f}, \quad (1)$$

节点电流注入满足基尔霍夫电流定律

$$\mathbf{Y}\dot{\mathbf{V}} = \dot{\mathbf{I}}. \quad (2)$$

节点 i 的复功率注入满足

$$S_i^N = P_i^N + \mathbf{j}Q_i^N = \dot{V}_i \hat{I}_i, \quad (3)$$

其中 $\hat{I}_i$ 表示电流的共轭。因此有

$$P_i^N - \mathbf{j}Q_i^N = \hat{V}_i \sum_{j \in \mathcal{N}} Y_{ij} \dot{V}_j, \quad i \in \mathcal{N}. \quad (4)$$

将 $\dot{V}_i = e_i + \mathbf{j}f_i$ 代入, 并分别比较实部和虚部, 可以得到矩形坐标下的 AC 潮流方程:

$$P_i^N = \sum_{j \in \mathcal{N}} [G_{ij}(e_i e_j + f_i f_j) - B_{ij}(e_i f_j - e_j f_i)], \quad i \in \mathcal{N}, \quad (5)$$

$$Q_i^N = \sum_{j \in \mathcal{N}} [-B_{ij}(e_i e_j + f_i f_j) - G_{ij}(e_i f_j - e_j f_i)], \quad i \in \mathcal{N}. \quad (6)$$

式 (5)–(6) 是电力系统优化中最重要也最困难的约束之一。它们包含电压变量之间的二次项, 因此一般是非线性且非凸的。由此, 基于精确 AC 潮流的最优潮流问题通常是非凸优化问题。

2.3 节点类型: Slack、PQ 与 PV

潮流方程中, 每个节点通常有四个相关变量: $P_i^N, Q_i^N, V_i, \theta_i$ 。为了使潮流方程可解, 需要根据节点物理属性给定其中两个变量。

- **Slack bus**: 平衡节点, 也称参考节点。通常给定 V_i 和 θ_i , 用于提供相角参考, 并承担系统功率不平衡和网损。
- **PQ bus**: 负荷节点。通常给定 P_i^N 和 Q_i^N , 求解 V_i 和 θ_i 。
- **PV bus**: 发电机节点。通常给定 P_i^N 和 V_i , 通过调节无功出力来维持电压幅值, 求解 Q_i^N 和 θ_i 。

在优化问题中, 上述“给定变量”不一定完全固定。例如在 OPF 中, 发电机有功、无功和电压幅值都可能成为决策变量; 而在传统潮流计算中, 它们通常作为输入或控制量给定。

2.4 DC Power Flow: 直流潮流近似

在经济调度、机组组合和市场出清中，模型规模通常很大。如果直接使用 AC 潮流，会引入非凸非线性约束，求解难度显著增加。因此，输电网优化中经常使用 **DC power flow**（直流潮流近似）。

考虑线路 (i, j) ，忽略电阻并假设线路电抗为 x_{ij} 。交流线路有功功率近似为

$$P_{ij} = \frac{V_i V_j \sin(\theta_i - \theta_j)}{x_{ij}}. \quad (7)$$

DC 潮流采用如下假设：

1. 电压幅值接近 1.0 p.u., 即 $V_i \approx V_j \approx 1$;
2. 相角差较小, $\sin(\theta_i - \theta_j) \approx \theta_i - \theta_j$;
3. 忽略线路电阻、网损和无功功率。

于是线路有功潮流可写为

$$P_{ij} = \frac{\theta_i - \theta_j}{x_{ij}}, \quad (i, j) \in \mathcal{L}. \quad (8)$$

将所有节点的有功平衡写成矩阵形式，可得

$$\mathbf{P}^N = \mathbf{B}' \boldsymbol{\theta}, \quad \theta_{\text{ref}} = 0, \quad (9)$$

其中 $\mathbf{B}'$ 是由线路电抗构造的节点电纳矩阵，参考节点相角设为零。

进一步地，可以消去相角变量，把线路潮流写成节点净注入的线性函数：

$$\mathbf{P}^{\text{line}} = \text{PTDF} \mathbf{P}^N, \quad (10)$$

其中 PTDF 为 **Power Transfer Distribution Factor**（功率转移分布因子）。PTDF 的含义是：节点注入发生单位变化时，各条线路潮流的线性变化量。

DC 潮流的适用性

DC 潮流适合高压输电网中的有功优化问题，例如 ED、UC、SCUC 和电力市场出清。它不适合需要精确描述电压、无功和网损的问题，例如电压稳定、无功优化、配电网电压控制和 Volt/Var 控制。

2.5 Branch Flow Model: 支路潮流模型及线性化

Branch Flow Model（支路潮流模型，BFM）常用于径向配电网。与 BIM 以节点电压为核心不同，BFM 直接使用支路有功、无功潮流和节点电压幅值作为变量，因此更贴近配电网量测与运行控制。

对于径向网络中的线路 (i, j) ，设

$$U_i = V_i^2, \quad I_{ij} = \frac{P_{ij}^2 + Q_{ij}^2}{U_i}. \quad (11)$$

则支路潮流方程可写为

$$P_{ij} - r_{ij}I_{ij} + P_j^N = \sum_{k \in c(j)} P_{jk}, \quad (12)$$

$$Q_{ij} - x_{ij}I_{ij} + Q_j^N = \sum_{k \in c(j)} Q_{jk}, \quad (13)$$

$$U_j = U_i - 2(r_{ij}P_{ij} + x_{ij}Q_{ij}) + (r_{ij}^2 + x_{ij}^2)I_{ij}, \quad (14)$$

$$U_i I_{ij} = P_{ij}^2 + Q_{ij}^2. \quad (15)$$

其中 $c(j)$ 表示节点 j 的子节点集合。式 (12)–(13) 表示有功和无功平衡；式 (14) 表示支路电压降；式 (15) 是非凸的二次等式。

若忽略线路损耗，即忽略 $r_{ij}I_{ij}$ 、 $x_{ij}I_{ij}$ 和 $(r_{ij}^2 + x_{ij}^2)I_{ij}$ ，可得到**线性化 BFM**：

$$P_{ij} + P_j^N = \sum_{k \in c(j)} P_{jk}, \quad (16)$$

$$Q_{ij} + Q_j^N = \sum_{k \in c(j)} Q_{jk}, \quad (17)$$

$$U_j = U_i - 2(r_{ij}P_{ij} + x_{ij}Q_{ij}). \quad (18)$$

与 DC 潮流相比，线性化 BFM 保留了无功功率和线路电阻对电压幅值的影响，因此更适合配电网。然而，BFM 的一个重要限制是：它主要适用于径向网络；对于网状输电网，DC 潮流或 BIM 通常更加自然。

2.6 OPF-BFM 及 SOCP 松弛

前面介绍的 BFM 可以直接用于径向网络潮流计算，但当它被嵌入 OPF 时，仍然会出现非凸约束。为了得到可由凸优化求解器高效处理的模型，一个常用做法是把 BFM 写成 **OPF-BFM**（基于支路潮流模型的最优潮流），再对其中唯一的非凸等式进行 **SOCP relaxation**（二阶锥松弛）。

考虑径向网络中的线路 $l = (i, j)$ ，引入两个平方变量：

$$U_i = V_i^2, \quad i \in \mathcal{N}, \quad (19)$$

$$I_{ij}^l = \frac{(P_{ij}^l)^2 + (Q_{ij}^l)^2}{V_i^2}, \quad l = (i, j) \in \mathcal{L}. \quad (20)$$

其中 U_i 是节点 i 的电压幅值平方， I_{ij}^l 是线路 l 上电流幅值平方。这样做的目的，是把原始 BFM 中含有分式和平方项的电压降关系改写为“线性等式 + 一个非凸二次等式”的结构。

在上述变量下，AC BFM 可写为

$$P_{ij}^l - r_{ij}^l I_{ij}^l + p_j^g = p_j^d + \sum_{k \in c(j)} P_{jk}^l, \quad j \in \mathcal{N}, \quad (21)$$

$$Q_{ij}^l - x_{ij}^l I_{ij}^l + q_j^g = q_j^d + \sum_{k \in c(j)} Q_{jk}^l, \quad j \in \mathcal{N}, \quad (22)$$

$$U_j = U_i - 2(P_{ij}^l r_{ij}^l + Q_{ij}^l x_{ij}^l) + (z_{ij}^l)^2 I_{ij}^l, \quad l = (i, j) \in \mathcal{L}, \quad (23)$$

$$U_i I_{ij}^l = (P_{ij}^l)^2 + (Q_{ij}^l)^2, \quad l = (i, j) \in \mathcal{L}. \quad (24)$$

式 (21) 和式 (22) 分别是节点有功、无功平衡；式 (23) 是支路电压降方程。注意，式 (21)–(23) 对变量 (P, Q, U, I) 都是线性的，非凸性集中在式 (24)。

若将发电机出力、电压幅值和线路容量等运行边界记为 Cons-BND，则 OPF-BFM 可以抽象写成

$$\begin{aligned} \min \quad & F_C \\ \text{s.t.} \quad & (21) - (24), \\ & \text{Cons-BND}, \end{aligned} \quad (25)$$

其中 F_C 通常表示发电成本、购电成本或网损成本。由于式 (24) 是旋转二阶锥的边界，模型 (25) 的可行域可以理解为“一个多面体与若干旋转二阶锥边界的交集”。

SOCP 松弛的关键步骤，是把非凸等式

$$U_i I_{ij}^l = (P_{ij}^l)^2 + (Q_{ij}^l)^2 \quad (26)$$

替换为不等式

$$U_i I_{ij}^l \geq (P_{ij}^l)^2 + (Q_{ij}^l)^2, \quad l = (i, j) \in \mathcal{L}. \quad (27)$$

该不等式可以写成标准二阶锥形式：

$$\left\| \begin{bmatrix} 2P_{ij}^l \\ 2Q_{ij}^l \\ I_{ij}^l - U_i \end{bmatrix} \right\|_2 \leq I_{ij}^l + U_i, \quad l = (i, j) \in \mathcal{L}. \quad (28)$$

于是，OPF-BFM 的 SOCP 松弛可概括为

$$\begin{aligned} \min \quad & F_C \\ \text{s.t.} \quad & (21) - (23), \\ & (28), \\ & \text{Cons-BND}. \end{aligned} \quad (29)$$

SOCP 松弛的直观含义

原始 OPF-BFM 要求变量 $(P_{ij}^l, Q_{ij}^l, U_i, I_{ij}^l)$ 落在二阶锥的边界上；SOCP 松弛则允许它们落在二阶锥内部或边界上。因此，松弛后的可行域更大，最优目标值通常给出原问题的下界。若最优解满足

$$U_i I_{ij}^l = (P_{ij}^l)^2 + (Q_{ij}^l)^2, \quad \forall l \in \mathcal{L},$$

则松弛是精确的，SOCP 解也就是原始 OPF-BFM 的可行最优解。

这个小问题说明了 BFM 在优化中的重要价值：通过平方电压和平方电流变量，除一个锥边界等式外，其余潮流约束都可以写成线性形式；进一步用二阶锥不等式替代该等式，就得到计算上更友好的凸优化模型。

2.7 不同潮流模型在优化中的选择

模型	典型适用场景	主要特点
AC BIM	精确 OPF、状态估计、电压无功优化	精确但非凸，包含电压幅值、相角、有功和无功
DC power flow	ED、UC、SCUC、市场出清	线性、快速，适合输电网有功优化，但忽略无功、电压和网损
AC BFM	径向配电网 OPF	直接描述支路潮流和节点电压，适合配电网
Linearized BFM	配电网运行优化、分布式能源调度	线性，保留电阻和无功对电压的影响，但忽略损耗
BFM-SOCP relaxation	径向网络 OPF、含配电网约束的凸优化建模	计算效率高，适合凸优化求解，但若松弛不精确，解可能不满足原始 AC 潮流等式

对于入门学习，可以把模型选择理解为以下逻辑：如果研究对象是输电网中的大规模调度问题，通常从 DC 潮流开始；如果研究对象是配电网电压与无功控制，通常从 BFM 或线性化 BFM 开始；如果研究目标需要精确物理可行性，则最终需要回到 AC 潮流模型。

3 Deterministic Optimization

本节介绍电力系统运行中的两个确定性优化模型：**Economic Dispatch**（经济调度，ED）和**Unit Commitment**（机组组合，UC）。所谓确定性优化，是指负荷、可再生能源出力、网络参数和设备状态均被视为已知量，不显式考虑随机性或不不确定性。

从时间尺度看，ED 通常用于较短时间尺度，在机组开停状态已知的前提下优化出力；UC 通常用于日前或多时段调度，需要同时决定机组启停状态和出力。因此，ED 通常是连续优化问题，而 UC 通常是混合整数优化问题。

3.1 Economic Dispatch: 经济调度

Economic Dispatch（经济调度）的目标是在满足负荷平衡和设备运行约束的条件下，确定各台在线机组的有功出力，使总发电成本最小。

3.1.1 无网络约束的单时段 ED

设在线机组集合为 $\mathcal{G}$ ，系统总负荷为 D ，机组 i 的出力为 p_i ，成本函数为

$$C_i(p_i) = a_i p_i^2 + b_i p_i + c_i, \quad a_i \geq 0. \quad (30)$$

最基本的 ED 模型为

$$\min_{\{p_i\}_{i \in \mathcal{G}}} \sum_{i \in \mathcal{G}} C_i(p_i) \quad (31)$$

$$\text{s.t.} \quad \sum_{i \in \mathcal{G}} p_i = D, \quad (32)$$

$$p_i^{\min} \leq p_i \leq p_i^{\max}, \quad i \in \mathcal{G}. \quad (33)$$

若暂时忽略出力上下限，则其拉格朗日函数为

$$\mathcal{L}(\mathbf{p}, \lambda) = \sum_{i \in \mathcal{G}} C_i(p_i) + \lambda \left(D - \sum_{i \in \mathcal{G}} p_i \right). \quad (34)$$

一阶最优性条件给出

$$\frac{dC_i(p_i^*)}{dp_i} = \lambda, \quad i \in \mathcal{G}. \quad (35)$$

式 (35) 被称为 **equal incremental cost principle** (等微增成本准则): 在没有阻塞和边界约束激活时，所有边际机组的边际发电成本相等。

若考虑机组出力上下限，则 KKT 条件可写为

$$\begin{cases} C'_i(p_i^*) = \lambda, & p_i^{\min} < p_i^* < p_i^{\max}, \\ C'_i(p_i^*) \geq \lambda, & p_i^* = p_i^{\min}, \\ C'_i(p_i^*) \leq \lambda, & p_i^* = p_i^{\max}. \end{cases} \quad (36)$$

这说明：达到上限或下限的机组不再按照等边际成本原则自由调节。

3.1.2 考虑网络约束的 DC-ED

在输电网中，经济调度还必须满足线路容量约束。采用 DC 潮流或 PTDF 表示，可建立网络约束经济调度模型：

$$\min_{\mathbf{p}} \sum_{i \in \mathcal{G}} C_i(p_i) \quad (37)$$

$$\text{s.t.} \quad \sum_{i \in \mathcal{G}} p_i + \sum_{j \in \mathcal{W}} w_j = \sum_{q \in \mathcal{D}} d_q, \quad (38)$$

$$p_i^{\min} \leq p_i \leq p_i^{\max}, \quad i \in \mathcal{G}, \quad (39)$$

$$-F_l^{\max} \leq \sum_{i \in \mathcal{G}} \pi_{il} p_i + \sum_{j \in \mathcal{W}} \pi_{jl} w_j - \sum_{q \in \mathcal{D}} \pi_{ql} d_q \leq F_l^{\max}, \quad l \in \mathcal{L}. \quad (40)$$

其中 w_j 是可再生能源预测出力， d_q 是负荷， π_{il} 、 π_{jl} 、 π_{ql} 是对应节点到线路 l 的 PTDF。

若线路约束没有激活，系统通常只有一个统一的边际电价；若线路约束激活，则不同节点的边际供电成本不同，从而形成 **Locational Marginal Price** (节点边际电价，LMP)。因此，网络约束 ED 是理解电力市场出清和节点电价的基础模型。

3.2 Unit Commitment: 机组组合

Unit Commitment (机组组合，UC) 在多时段尺度上决定每台机组在每个时段是否开机，并确定其发电出力。与 ED 相比，UC 的困难在于引入了二进制变量和跨时段约束，例如最小开机时间、最小停机时间、爬坡约束、启停成本等。

设调度时段集合为 $\mathcal{T} = \{1, 2, \dots, T\}$ 。定义二进制变量

$$z_{it} = \begin{cases} 1, & \text{机组 } i \text{ 在时段 } t \text{ 开机,} \\ 0, & \text{机组 } i \text{ 在时段 } t \text{ 停机,} \end{cases} \quad (41)$$

并定义启动变量 u_{it} 和停机变量 v_{it} ：

$$u_{it} = 1 \Rightarrow \text{机组 } i \text{ 在时段 } t \text{ 启动}, \quad v_{it} = 1 \Rightarrow \text{机组 } i \text{ 在时段 } t \text{ 停机}. \quad (42)$$

3.2.1 确定性 UC 的目标函数

确定性 UC 的典型目标是最小化多时段总成本：

$$\min \sum_{t \in \mathcal{T}} \sum_{i \in \mathcal{G}} (SU_i u_{it} + SD_i v_{it} + a_i p_{it}^2 + b_i p_{it} + c_i z_{it}), \quad (43)$$

其中 SU_i 和 SD_i 分别为启动成本和停机成本， p_{it} 是机组 i 在时段 t 的有功出力。若需要得到严格 MILP，可将二次成本函数分段线性化；若求解器支持 MIQP，也可以直接保留凸二次成本。

3.2.2 启停逻辑约束

机组状态与启动、停机变量之间的逻辑关系可写为

$$z_{it} - z_{i,t-1} = u_{it} - v_{it}, \quad i \in \mathcal{G}, t \in \mathcal{T}, \quad (44)$$

$$u_{it}, v_{it}, z_{it} \in \{0, 1\}, \quad i \in \mathcal{G}, t \in \mathcal{T}. \quad (45)$$

式 (44) 表示：若状态从 0 变为 1，则发生启动；若状态从 1 变为 0，则发生停机。

3.2.3 最小开机与最小停机时间

火电机组由于热力过程和设备安全限制，不能频繁启停。设 T_i^{on} 和 T_i^{off} 分别为最小开机和最小停机时间，则可写成

$$\sum_{\tau=t}^{t+T_i^{\text{on}}-1} z_{i\tau} \geq T_i^{\text{on}} u_{it}, \quad i \in \mathcal{G}, t \in \mathcal{T}, \quad (46)$$

$$\sum_{\tau=t}^{t+T_i^{\text{off}}-1} (1 - z_{i\tau}) \geq T_i^{\text{off}} v_{it}, \quad i \in \mathcal{G}, t \in \mathcal{T}. \quad (47)$$

式 (46) 表示：如果机组在时段 t 启动，则之后至少连续开机 T_i^{on} 个时段；式 (47) 表示：如果机组在时段 t 停机，则之后至少连续停机 T_i^{off} 个时段。

3.2.4 出力上下限与爬坡约束

机组只有在开机时才能发电，因此有

$$z_{it} p_i^{\min} \leq p_{it} \leq z_{it} p_i^{\max}, \quad i \in \mathcal{G}, t \in \mathcal{T}. \quad (48)$$

爬坡约束描述相邻时段之间的出力变化限制：

$$p_{it} - p_{i,t-1} \leq R_i^+, \quad i \in \mathcal{G}, t \in \mathcal{T}, \quad (49)$$

$$p_{i,t-1} - p_{it} \leq R_i^-, \quad i \in \mathcal{G}, t \in \mathcal{T}. \quad (50)$$

在更精细的 UC 模型中，爬坡约束还会区分正常运行、启动过程和停机过程。例如可以引入启动爬坡能力和停机爬坡能力，使模型更贴近机组物理过程。

3.2.5 功率平衡与网络约束

在每个时段，系统有功功率需要满足平衡：

$$\sum_{i \in \mathcal{G}} p_{it} + \sum_{j \in \mathcal{W}} w_{jt}^f = \sum_{q \in \mathcal{D}} d_{qt}, \quad t \in \mathcal{T}, \quad (51)$$

其中 w_{jt}^f 表示时段 t 中可再生能源 j 的确定性预测出力。

若考虑输电网络约束，则使用 PTDF 得到

$$-F_l^{\max} \leq \sum_{i \in \mathcal{G}} \pi_{il} p_{it} + \sum_{j \in \mathcal{W}} \pi_{jl} w_{jt}^f - \sum_{q \in \mathcal{D}} \pi_{ql} d_{qt} \leq F_l^{\max}, \quad l \in \mathcal{L}, t \in \mathcal{T}. \quad (52)$$

因此，一个确定性的网络约束 UC 可以概括为

$$\min_{\mathbf{p}, \mathbf{z}, \mathbf{u}, \mathbf{v}} \sum_{t \in \mathcal{T}} \sum_{i \in \mathcal{G}} (SU_i u_{it} + SD_i v_{it} + C_i(p_{it})) \quad (53)$$

$$\text{s.t.} \quad (44) - (52). \quad (54)$$

该模型是典型的 MILP 或 MIQP。其核心难点来自两个方面：第一，二进制变量 z_{it}, u_{it}, v_{it} 使问题具有组合复杂性；第二，跨时段约束使不同时间段的决策不能独立求解。

3.3 ED 与 UC 的关系

ED 和 UC 的关系可以理解为“先决定哪些机组可用，再决定这些机组如何出力”。在给定 UC 的开机状态 z_{it} 后，每个时段的 UC 会退化为一个带有出力上下限、爬坡约束和网络约束的 ED 问题：

$$\text{UC} = \text{commitment decisions} + \text{dispatch decisions}, \quad (55)$$

其中 commitment decisions 是二进制启停决策，dispatch decisions 是连续出力决策。

确定性运行优化的基本层次

- **ED**：已知机组在线状态，优化连续出力；通常是 LP、QP 或凸优化问题。
- **UC**：同时优化机组启停状态和连续出力；通常是 MILP 或 MIQP。
- **OPF**：强调网络物理约束；若采用 AC 潮流则非凸，若采用 DC 潮流则常形成线性或凸模型。
- **SCUC**：在 UC 基础上加入网络安全约束，是日前市场和安全调度中的核心模型。

3.4 小结

确定性 ED 和 UC 是电力系统优化的基础模型。ED 关注“在线机组如何经济分配出力”，UC 进一步关注“哪些机组应该在何时开机或停机”。在工程应用中，DC 潮流和 PTDF 常被用于把网络约束嵌入 ED 和 UC；而当需要更精确的电压、无功和网损建模时，则需要引入 AC 潮流或支路潮流模型。

4 Optimization Under Uncertainty: Robust Optimization

本节整理不确定性优化的基本框架，主要参考附录 C “Basics of Robust Optimization” 中关于静态鲁棒优化、可调鲁棒优化、分布鲁棒优化与数据驱动鲁棒随机规划的介绍。对于电力系统优化而言，不确定性主要来自负荷预测误差、风电/光伏出力偏差、电价波动、设备故障以及外部环境扰动。若直接采用确定性优化模型，调度方案只对一个预测场景有效；一旦真实场景偏离预测值，可能出现功率平衡破坏、线路越限、备用不足或市场结算风险。因此，不确定性优化的基本目标是：在成本、保守性和可计算性之间取得平衡。

本节的主线如下：

$$\text{static RO} \rightarrow \text{adjustable RO} \rightarrow \text{DRO} \rightarrow \text{data-driven robust stochastic program.} \quad (56)$$

其中，static RO 只要求一个固定决策在所有不确定场景下可行；adjustable RO 允许部分决策在不确定性揭示后调整；DRO 不再假设一个精确概率分布，而是在概率分布集合中考虑最坏情况；data-driven robust stochastic program 则进一步强调由历史样本构造分布歧义集，使模型同时具有随机优化的数据利用能力和鲁棒优化的安全性。

4.1 符号约定与一般建模思路

为避免符号混乱，本节先给出统一记号。设 x 表示优化决策， w 或 ξ 表示不确定变量， $\mathcal{W}$ 表示不确定变量的支持集， $\mathcal{P}$ 或 $\mathcal{D}$ 表示候选概率分布的集合。常见对象如下表。

符号	含义	电力系统示例
x	here-and-now 决策	机组启停、日前发电计划、备用容量
$y(w)$	wait-and-see 决策/二阶段补救决策	实时出力调整、AGC 响应、弃风弃光、负荷削减
w, ξ	不确定变量	风电预测误差、光伏预测误差、负荷预测误差
$\mathcal{W}$	不确定集合/support set	多面体区间、预算不确定集、椭球不确定集
$\mathbb{P}$	概率分布	风电误差的真实但未知分布
$\mathcal{D}$	歧义集/ambiguity set	具有相同矩或与经验分布距离不超过半径的概率分布集合
$\mathbb{E}_{\mathbb{P}}[\cdot]$	在分布 $\mathbb{P}$ 下的期望	期望运行成本、期望弃风量
$\text{CVaR}_{\epsilon}(\cdot)$	条件风险价值	高损失尾部风险、越限风险度量

一个确定性线性优化模型可以写为

$$\begin{aligned} \min_x \quad & c^\top x \\ \text{s.t.} \quad & Ax \leq b. \end{aligned} \quad (57)$$

当 A, b, c 中某些参数不确定时，模型不再只对应一个优化问题，而对应一族随不确定参数变化的优化问题。附录 C 先从带不确定系数的线性规划出发：

$$\min_x \left\{ c^\top x \mid Ax \leq b \right\}, \quad (A, b, c) \in \mathcal{W}. \quad (58)$$

通过引入 epigraph 变量, 可以把目标函数系数和右端项中的不确定性转移到约束系数中。因此在介绍基本理论时, 常把不确定性集中写在矩阵 A 中:

$$\min_x \left\{ c^\top x \mid Ax \leq b \right\}, \quad A \in \mathcal{W}. \quad (59)$$

这种写法并不意味着实际问题中只有 A 不确定, 而是为了突出鲁棒约束的本质。

4.2 静态鲁棒优化 (Static Robust Optimization)

4.2.1 基本思想: 一个固定决策应对所有场景

静态鲁棒优化 (static robust optimization, static RO) 的核心假设是: 所有决策变量都是 **here-and-now decision** (事前决策), 即必须在不确定参数真实取值揭示之前确定。一旦决策 x 被确定, 只要真实参数落在预先给定的不确定集合 $\mathcal{W}$ 中, 约束就必须可行。

对于模型 (59), 一个向量 x 是鲁棒可行的, 当且仅当

$$Ax \leq b, \quad \forall A \in \mathcal{W}. \quad (60)$$

于是静态鲁棒对应问题 (robust counterpart, RC) 为

$$\begin{aligned} \min_x \quad & c^\top x \\ \text{s.t.} \quad & a_i^\top x \leq b_i, \quad \forall i, \forall A \in \mathcal{W}, \end{aligned} \quad (61)$$

其中 $a_i^\top$ 是 A 的第 i 行。该模型的直观含义是: 不再只检查一个预测矩阵 $\bar{A}$, 而要检查所有可能矩阵 $A \in \mathcal{W}$ 。

在电力系统中, 静态 RO 的典型形式可以理解为:

$$\begin{aligned} \min_x \quad & \text{日前运行成本} \\ \text{s.t.} \quad & \text{网络安全约束在所有 } w \in \mathcal{W} \text{ 下成立.} \end{aligned} \quad (62)$$

例如, 在一个基于 DC 潮流的调度模型中, 若风电预测误差为 w , 线路潮流可以表示为 $F(x, w)$, 则静态鲁棒线路约束为

$$-\bar{f} \leq F(x, w) \leq \bar{f}, \quad \forall w \in \mathcal{W}. \quad (63)$$

这类模型可以保证安全, 但由于 x 不能随 w 调整, 因此通常比较保守。

4.2.2 约束分解性质与凸包性质

静态 RO 有两个非常重要的结构性质。

第一, **constraint-wise property** (逐约束性质): 由于每一行约束都必须对所有不确定参数成立, 鲁棒可行性只与每一行系数的不确定投影有关。令

$$\mathcal{W}_i = \{a_i \mid \exists A \in \mathcal{W}\}, \quad (64)$$

则约束

$$a_i^\top x \leq b_i, \text{ for all } i, \forall A \in \mathcal{W} \quad (65)$$

等价于

$$a_i^\top x \leq b_i, \quad \forall a_i \in \mathcal{W}_i, \quad \forall i. \quad (66)$$

因此，在静态 RO 中，即使原始不确定集合 $\mathcal{W}$ 中各行之间存在相关性，只要每一行的投影集合不变，鲁棒可行解集合就不变。这一点在直觉上可能显得保守，因为行与行之间的相关结构被“拆开”了。

第二，**convex hull property** (凸包性质)：若 x 对集合 $\mathcal{W}_i$ 中的所有极点都可行，则它对 $\text{conv}(\mathcal{W}_i)$ 中任意凸组合也可行。也就是说，静态 RO 的鲁棒可行解不会因为把不确定集合替换为闭凸包而改变：

$$\mathcal{W}_i \longrightarrow \text{conv}(\mathcal{W}_i). \quad (67)$$

因此，通常可假设不确定集合是闭凸集或若干闭凸集的笛卡尔积。

4.2.3 鲁棒约束与最坏情形重构

考虑单条不确定线性约束。设不确定系数向量被参数化为

$$a = \bar{a} + P\zeta, \quad (68)$$

其中 $\bar{a}$ 是名义值， P 描述不确定扰动的方向和尺度， ζ 是标准化不确定变量， $\mathcal{Z}$ 是 ζ 的不确定集合。鲁棒约束为

$$(\bar{a} + P\zeta)^\top x \leq b, \quad \forall \zeta \in \mathcal{Z}. \quad (69)$$

它等价于要求最坏情况下左端项也不超过 b ：

$$\bar{a}^\top x + \max_{\zeta \in \mathcal{Z}} (P^\top x)^\top \zeta \leq b. \quad (70)$$

式 (70) 中的

$$\sigma_{\mathcal{Z}}(P^\top x) := \max_{\zeta \in \mathcal{Z}} (P^\top x)^\top \zeta \quad (71)$$

是集合 $\mathcal{Z}$ 的支撑函数。因此静态 RO 的关键是：对不同 $\mathcal{Z}$ ，如何把支撑函数约束转化为可求解的确定性约束。

Polyhedral uncertainty set. 若不确定集合为多面体

$$\mathcal{Z} = \{\zeta \mid D\zeta + q \geq 0\}, \quad (72)$$

则最坏项

$$\max_{\zeta} \left\{ (P^\top x)^\top \zeta \mid D\zeta + q \geq 0 \right\} \quad (73)$$

是一个线性规划。利用线性规划对偶，可以得到等价的有限维确定性约束：存在对偶变量 $u \geq 0$ ，使得

$$\begin{aligned} \bar{a}^\top x + q^\top u &\leq b, \\ D^\top u + P^\top x &= 0, \\ u &\geq 0. \end{aligned} \quad (74)$$

因此，如果每条鲁棒约束都有多面体不确定集合，原问题仍可转化为线性规划：

$$\begin{aligned} \min_x \quad & c^\top x \\ \text{s.t.} \quad & \bar{a}_i^\top x + q_i^\top u_i \leq b_i, \quad \forall i, \\ & D_i^\top u_i + P_i^\top x = 0, \quad u_i \geq 0, \quad \forall i. \end{aligned} \quad (75)$$

这也是静态 RO 在工程应用中非常重要的原因：只要不确定集合选得合适，半无限约束可以被对偶化为有限个线性约束。

Cardinality constrained uncertainty set. 预算不确定集 (cardinality constrained uncertainty set) 常用于描述“每个参数都可能偏离预测值, 但不太可能所有参数同时达到最坏偏差”的情形。典型形式为

$$\mathcal{Z}(\Gamma) = \left\{ \zeta \left| -1 \leq \zeta_j \leq 1, \sum_j |\zeta_j| \leq \Gamma \right. \right\}, \quad (76)$$

其中 Γ 是不确定性预算。 $\Gamma = 0$ 时退化为名义模型; Γ 越大, 模型越保守; 当 Γ 大于变量维数时, 预算约束基本失效。

为了求解, 常引入辅助变量 σ_j 将绝对值线性化:

$$\mathcal{Z}(\Gamma) = \left\{ (\zeta, \sigma) \left| -\sigma_j \leq \zeta_j \leq \sigma_j, 0 \leq \sigma_j \leq 1, \sum_j \sigma_j \leq \Gamma \right. \right\}. \quad (77)$$

这表明预算不确定集本质上仍是多面体, 因此可以继续使用 LP 对偶获得鲁棒对应问题。

Norm-ball uncertainty set. 若 $\mathcal{Z}$ 是范数球, 例如

$$\mathcal{Z} = \{\zeta \mid \|\zeta\|_2 \leq \rho\}, \quad (78)$$

则由 Cauchy-Schwarz 不等式可得

$$\max_{\|\zeta\|_2 \leq \rho} (P^\top x)^\top \zeta = \rho \|P^\top x\|_2. \quad (79)$$

鲁棒约束等价于二阶锥约束

$$\bar{a}^\top x + \rho \|P^\top x\|_2 \leq b. \quad (80)$$

因此, 椭球型不确定集合通常导致 SOCP。若使用 ℓ_∞ 或 ℓ_1 范数球, 则可能得到线性或可线性化的鲁棒对应约束。

4.2.4 静态 RO 的建模特点

静态 RO 的优点是模型逻辑清晰、鲁棒可行性强、求解形式通常可控。它适合用于以下场景:

- 不确定参数只出现在不等式约束中, 例如线路容量裕度、资源容量上界、价格波动约束;
- 决策确实必须全部事前确定, 例如长期投资规划中的容量决策;
- 决策者更重视可行性保证, 而不是期望成本最优。

它的局限也很明显。首先, 若不确定参数进入等式约束, 例如功率平衡

$$\sum_{g \in \mathcal{G}} p_g = d - w, \quad \forall w \in \mathcal{W}, \quad (81)$$

而所有 p_g 都是静态决策, 则除非 w 不变化, 否则一个固定 p_g 无法同时满足所有场景的等式。其次, 静态 RO 忽略了实际运行中的补救能力。例如机组出力、储能充放电、需求响应和弃风弃光都可以在实时阶段根据误差调整。如果把这些调整能力也固定在事前决策中, 模型会过度保守。

4.3 可调鲁棒优化 (Adjustable Robust Optimization, ARO)

4.3.1 先行决策与等待观察决策

可调鲁棒优化 (adjustable robust optimization, ARO) 正是为了缓解静态 RO 的保守性。它区分两类变量：

- x : **here-and-now decision** (事前决策), 在不确定性揭示前确定;
- $y(w)$: **wait-and-see decision** (事后/补救决策), 可以在观察到 w 后选择。

两阶段 ARO 的基本约束可以写为

$$Ax + By(w) + Cw \leq b, \quad \forall w \in \mathcal{W}. \quad (82)$$

其含义是：对每个可能的 w , 在已给定事前决策 x 的情况下, 都存在一个可行补救动作 $y(w)$ 使系统安全。

更完整地, 可以定义二阶段可行集合

$$\mathcal{Y}(x, w) = \{y \mid Ax + By + Cw \leq b\}. \quad (83)$$

则 x 是 adjustable robust feasible 的条件为

$$\mathcal{Y}(x, w) \neq \emptyset, \quad \forall w \in \mathcal{W}. \quad (84)$$

在电力系统机组组合中, 这种结构非常自然:

$$\underbrace{x}_{\text{机组启停、日前计划}} \xrightarrow{w \text{ 揭示}} \underbrace{y(w)}_{\text{实时出力、备用调用、弃风/切负荷}}. \quad (85)$$

因此, ARO 比静态 RO 更贴近实际调度流程。

4.3.2 ARO 中的成本准则

ARO 的目标函数可以有多种形式。若只优化名义场景下的成本, 可写为

$$\begin{aligned} \min_{x, y(\cdot)} \quad & c^\top x + d^\top y(0) \\ \text{s.t.} \quad & Ax + By(w) + Cw \leq b, \quad \forall w \in \mathcal{W}. \end{aligned} \quad (86)$$

若关注最坏场景下的一、二阶段总成本, 则可写为

$$\begin{aligned} \min_{x, y(\cdot)} \quad & c^\top x + \max_{w \in \mathcal{W}} d^\top y(w) \\ \text{s.t.} \quad & Ax + By(w) + Cw \leq b, \quad \forall w \in \mathcal{W}. \end{aligned} \quad (87)$$

前者更像“保证安全的名义最优”, 后者更像“成本也要抗最坏情形”。在电力系统中, 若实时补救成本很高, 例如高价备用、负荷削减或弃风惩罚, 则式 (87) 更合理。

4.3.3 仿射决策规则近似

完全可调 ARO 的困难在于 $y(w)$ 是一个函数变量，理论上可以是任意函数，通常没有封闭形式。为了得到可计算模型，附录 C 重点介绍了 **affine policy**（仿射策略/线性决策规则）：

$$y(w) = y_0 + Gw, \quad (88)$$

其中 y_0 是名义场景 $w = 0$ 下的二阶段动作， G 是响应增益矩阵。代入约束 (82) 得

$$Ax + By_0 + (BG + C)w \leq b, \quad \forall w \in \mathcal{W}. \quad (89)$$

此时真正需要事前优化的变量变为 x, y_0, G ，而实时阶段只需根据 w 代入 $y(w) = y_0 + Gw$ 即可。

若不确定集合是多面体

$$\mathcal{W} = \{w \mid Sw \leq h\}, \quad (90)$$

并采用名义成本准则，则仿射 ARO 可转化为线性规划。对于第 i 条约束，需要

$$\max_{w \in \mathcal{W}} (BG + C)_i w \leq 0. \quad (91)$$

由 LP 对偶，可引入对偶变量矩阵 Λ ，得到

$$\begin{aligned} \min_{x, y_0, G, \Lambda} \quad & c^\top x + d^\top y_0 \\ \text{s.t.} \quad & Ax + By_0 \leq b, \\ & \Lambda h \leq 0, \\ & \Lambda \geq 0, \\ & \Lambda S = BG + C. \end{aligned} \quad (92)$$

这个模型说明：仿射策略的优势在于同时降低静态 RO 的保守性并保持可计算性。对于电力系统， G 可以解释为备用或 AGC 参与因子矩阵；若 w 表示风电误差， Gw 表示机组/储能/需求响应对误差的线性补偿。

4.3.4 完全可调模型与 CCG 算法

仿射策略并不总是最优，因为真实最优 $y(w)$ 可能是分段线性或非线性函数。完全可调模型通常写为

$$\begin{aligned} \min_x \quad & c^\top x + \max_{w \in \mathcal{W}} Q(x, w) \\ \text{s.t.} \quad & x \in \mathcal{X}, \end{aligned} \quad (93)$$

其中二阶段值函数为

$$Q(x, w) = \min_y \left\{ d^\top y \mid Ax + By + Cw \leq b, y \in \mathcal{Y} \right\}. \quad (94)$$

这类模型的常用算法是 **column-and-constraint generation**（列与约束生成，CCG）。其基本思想是：

1. 先在有限场景集合 $\mathcal{W}^k = \{w^1, \dots, w^k\}$ 上求主问题；

2. 给定当前 x^k ，求解子问题寻找最坏场景

$$w^{k+1} \in \arg \max_{w \in \mathcal{W}} Q(x^k, w); \quad (95)$$

3. 若最坏场景没有造成新的违反或上下界差距足够小，则停止；否则把 w^{k+1} 加入主问题并继续迭代。

在两阶段鲁棒机组组合中，主问题包含机组启停与已经发现的若干风电误差场景；子问题检查是否存在某个新的误差场景使实时调度不可行或成本更高。这样可以避免一开始枚举所有场景。

4.3.5 ARO 的建模特点

ARO 的关键价值是把“鲁棒性”与“适应性”结合起来。与 static RO 相比，它的特点如下：

模型	决策机制	特点
Static RO	所有变量都是事前固定	简单、保守，容易处理不等式不确定性
ARO	部分变量可随 w 调整	更贴近多阶段调度，保守性较低
Affine ARO	$y(w) = y_0 + Gw$	可计算性好，常得到 LP/SOCP/MILP
Fully adjustable ARO	$y(w)$ 任意可行函数	表达能力强，但计算困难，常用 CCG

4.4 分布鲁棒优化 (Distributionally Robust Optimization, DRO)

4.4.1 从不确定取值到不确定分布

传统 RO 假设不确定变量 w 落在集合 $\mathcal{W}$ 中，但不关心 w 的概率分布。随机优化 (stochastic optimization, SO) 通常假设概率分布 $\mathbb{P}$ 已知，然后优化期望成本：

$$\min_x c^\top x + \mathbb{E}_{\mathbb{P}}[Q(x, w)]. \quad (96)$$

然而在实际电力系统中，风电/光伏误差的真实分布往往未知，历史样本有限，且分布可能随季节和天气变化。分布鲁棒优化 (distributionally robust optimization, DRO) 介于 RO 和 SO 之间：它不假设唯一分布，而是假设真实分布属于一个歧义集 $\mathcal{D}$ ，并对最坏分布优化。

静态 DRO 的典型形式为

$$\begin{aligned} \min_x \quad & c^\top x + \sup_{\mathbb{P} \in \mathcal{D}} \mathbb{E}_{\mathbb{P}}[Q(x, w)] \\ \text{s.t.} \quad & x \in \mathcal{X}. \end{aligned} \quad (97)$$

其中 $\sup_{\mathbb{P} \in \mathcal{D}}$ 表示在所有候选概率分布中取最坏期望。若 $\mathcal{D}$ 只包含一个分布，式 (97) 退化为随机优化；若只关心支持集而不利用概率信息，则更接近传统 RO。

4.4.2 矩信息歧义集

矩歧义集 (moment ambiguity set) 用均值、协方差等矩信息描述候选分布。例如，给定支持集 $\mathcal{W}$ 、均值 μ 和协方差矩阵 Σ ，可定义

$$\mathcal{D}_{\text{mom}} = \left\{ \mathbb{P} \mid \mathbb{P}(w \in \mathcal{W}) = 1, \mathbb{E}_{\mathbb{P}}[w] = \mu, \mathbb{E}_{\mathbb{P}}[(w - \mu)(w - \mu)^\top] = \Sigma \right\}. \quad (98)$$

它的思想是：即使不知道完整分布，也可以从历史数据或预测模型估计均值和协方差，然后要求模型在所有满足这些矩信息的分布下都表现稳健。

在电力系统中，矩歧义集适合描述：

- 风电预测误差的均值接近零，但方差随预测时段变化；
- 多个风电场误差之间存在相关性，因此需要协方差矩阵；
- 负荷误差的分布形状未知，但一阶和二阶统计量较容易估计。

矩 DRO 常见结果是得到 LP、SOCP 或 SDP 形式的鲁棒对应问题。尤其当只给定均值和协方差时，最坏期望或最坏机会约束通常与半定约束相关。

4.4.3 鲁棒机会约束

在安全约束中，很多时候不要求“所有场景都可行”，而要求“违反概率足够小”。若分布已知，机会约束为

$$\mathbb{P}\{g(x, w) \leq 0\} \geq 1 - \epsilon. \quad (99)$$

DRO 将其强化为对所有候选分布都成立：

$$\inf_{\mathbb{P} \in \mathcal{D}} \mathbb{P}\{g(x, w) \leq 0\} \geq 1 - \epsilon, \quad (100)$$

或等价地

$$\sup_{\mathbb{P} \in \mathcal{D}} \mathbb{P}\{g(x, w) > 0\} \leq \epsilon. \quad (101)$$

在 OPF 或经济调度中， $g(x, w)$ 可以表示线路潮流越限、节点电压越限、备用不足等事件。DRO chance constraint 的意义是：即使真实分布不是经验分布，只要它落在歧义集中，约束违反概率仍不超过 ϵ 。

4.4.4 最坏情形 CVaR 约束

机会约束通常难以直接处理，常用 CVaR 构造保守但可处理的替代形式。对随机损失 $Z = g(x, w)$ ，置信水平 $1 - \epsilon$ 下的 CVaR 可以写为

$$\text{CVaR}_\epsilon^\mathbb{P}(Z) = \inf_{\eta \in \mathbb{R}} \left\{ \eta + \frac{1}{\epsilon} \mathbb{E}_\mathbb{P}[(Z - \eta)_+] \right\}. \quad (102)$$

分布鲁棒 CVaR 约束为

$$\sup_{\mathbb{P} \in \mathcal{D}} \text{CVaR}_\epsilon^\mathbb{P}(g(x, w)) \leq 0. \quad (103)$$

如果式 (103) 成立，通常可以推出对应的分布鲁棒机会约束成立或得到其保守近似。对电力系统而言，CVaR 的优势是它不仅关心是否越限，还关心越限程度的尾部平均风险，因此比单纯的概率约束更适合风险限制调度。

4.4.5 可调分布鲁棒优化

DRO 也可以与 ARO 结合，形成可调分布鲁棒优化。基本形式为

$$\begin{aligned} \min_{x, y(\cdot)} \quad & c^\top x + \sup_{\mathbb{P} \in \mathcal{D}} \mathbb{E}_\mathbb{P}[d^\top y(w)] \\ \text{s.t.} \quad & Ax + By(w) + Cw \leq b, \quad \forall w \in \mathcal{W}. \end{aligned} \quad (104)$$

若采用仿射策略 $y(w) = y_0 + Gw$ ，则模型同时具有三层含义：

$$\text{事前决策 } x \quad + \quad \text{线性补救策略 } G \quad + \quad \text{最坏概率分布 } \mathbb{P} \in \mathcal{D}. \quad (105)$$

这类模型常见于含新能源的机组组合、备用调度和 OPF。其难点在于既要处理约束对所有 $w \in \mathcal{W}$ 可行，又要处理目标或风险对所有 $\mathbb{P} \in \mathcal{D}$ 稳健。

4.4.6 DRO 的建模特点

DRO 的建模逻辑可概括为：

$$\text{不确定变量 } w \longrightarrow \text{不确定分布 } \mathbb{P} \longrightarrow \text{歧义集 } \mathcal{D} \longrightarrow \text{最坏分布下优化}. \quad (106)$$

它的优势是比传统 RO 更充分利用统计信息，通常比只依赖支持集的 RO 不那么保守；同时又比经典 SO 更安全，因为它不把经验分布当成完全正确的真实分布。其局限在于：歧义集的选择直接决定模型保守性和可求解性。矩歧义集较成熟，但可能只捕捉低阶统计信息；复杂歧义集能更好利用数据，但推导鲁棒对应问题更困难。

4.5 数据驱动鲁棒随机规划 (Data-Driven Robust Stochastic Program)

4.5.1 为什么需要数据驱动？

数据驱动鲁棒随机规划 (data-driven robust stochastic program) 在概念上与 DRO 非常接近，重点是从历史样本构造歧义集。设已有 N 个样本

$$\widehat{\mathcal{W}}_N = \{\hat{w}^1, \hat{w}^2, \dots, \hat{w}^N\}. \quad (107)$$

经验分布为

$$\widehat{\mathbb{P}}_N = \frac{1}{N} \sum_{k=1}^N \delta_{\hat{w}^k}, \quad (108)$$

其中 $\delta_{\hat{w}^k}$ 是位于样本点 $\hat{w}^k$ 的 Dirac 分布。经典样本平均近似 (sample average approximation, SAA) 会直接使用 $\widehat{\mathbb{P}}_N$ ：

$$\min_x c^\top x + \frac{1}{N} \sum_{k=1}^N Q(x, \hat{w}^k). \quad (109)$$

但若样本量有限，经验分布可能偏离真实分布。数据驱动鲁棒随机规划则构造一个以经验分布为中心的歧义集，例如

$$\mathcal{D}_N = \{\mathbb{P} \mid d(\mathbb{P}, \widehat{\mathbb{P}}_N) \leq \theta_N\}, \quad (110)$$

并求解

$$\min_x c^\top x + \sup_{\mathbb{P} \in \mathcal{D}_N} \mathbb{E}_{\mathbb{P}}[Q(x, w)]. \quad (111)$$

其中 $d(\cdot, \cdot)$ 是分布距离， θ_N 是半径，通常随样本数量增加而减小。

4.5.2 基于散度的歧义集

常见数据驱动歧义集可以分为两类： ϕ -divergence 歧义集和 Wasserstein 歧义集。

对于离散样本空间， ϕ -divergence 通常比较候选概率权重 $p = (p_1, \dots, p_N)$ 与经验权重 $\hat{p} = (1/N, \dots, 1/N)$ 的差异：

$$\mathcal{D}_\phi = \left\{ p \in \mathbb{R}_+^N \mid \sum_{k=1}^N p_k = 1, \sum_{k=1}^N \hat{p}_k \phi\left(\frac{p_k}{\hat{p}_k}\right) \leq \theta \right\}. \quad (112)$$

不同的 ϕ 函数对应不同距离，例如 KL divergence、 χ^2 divergence 等。这类集合适合样本空间固定、主要担心概率权重估计误差的情况。

Wasserstein 歧义集则允许概率质量在样本点附近移动。其形式可写为

$$\mathcal{D}_W = \left\{ \mathbb{P} \mid W_p(\mathbb{P}, \hat{\mathbb{P}}_N) \leq \theta \right\}, \quad (113)$$

其中 W_p 是 Wasserstein 距离。它不仅考虑样本概率权重，也考虑样本点在空间中的距离，因此适合连续型不确定变量，例如风电误差、光伏误差和负荷误差。

4.5.3 鲁棒机会约束随机规划

附录 C.4 强调的一类重要问题是鲁棒机会约束随机规划。若风险事件为 $g(x, w) > 0$ ，数据驱动鲁棒机会约束为

$$\sup_{\mathbb{P} \in \mathcal{D}_N} \mathbb{P}\{g(x, w) > 0\} \leq \epsilon. \quad (114)$$

这个约束可解释为：在与历史样本相容的一族概率分布中，即使选择最不利的分布，违反概率也不超过 ϵ 。

在电力系统 OPF 中，可以令

$$g_\ell^+(x, w) = f_\ell(x, w) - \bar{f}_\ell, \quad g_\ell^-(x, w) = -f_\ell(x, w) - \bar{f}_\ell, \quad (115)$$

分别描述线路 ℓ 正向和反向越限。则数据驱动鲁棒机会约束可写为

$$\sup_{\mathbb{P} \in \mathcal{D}_N} \mathbb{P} \left\{ \max_{\ell} \{g_\ell^+(x, w), g_\ell^-(x, w)\} > 0 \right\} \leq \epsilon. \quad (116)$$

该式能够把“样本数据”“分布不确定性”和“网络安全风险”放在同一个模型中。

4.5.4 与随机规划和鲁棒优化的关系

数据驱动鲁棒随机规划可以看作 SO 与 RO 的桥梁：

$$\begin{aligned} \text{SO} & : \quad \text{假设 } \mathbb{P} \text{ 已知, 优化 } \mathbb{E}_{\mathbb{P}}[\cdot], \\ \text{RO} & : \quad \text{不使用概率分布, 只要求 } w \in \mathcal{W} \text{ 内可行}, \\ \text{Data-driven DRO} & : \quad \text{用样本构造 } \mathcal{D}_N, \text{ 优化最坏分布表现}. \end{aligned} \quad (117)$$

当 $\theta_N = 0$ 时， $\mathcal{D}_N$ 退化为经验分布，模型接近 SAA；当 θ_N 较大时，候选分布范围变宽，模型更保守；随着样本数量增加，通常可以缩小 θ_N ，使模型从保守逐步过渡到更接近真实随机优化。

4.6 面向电力系统优化的统一视角

为了帮助入门者理解四类模型之间的区别，表 6 给出统一对比。

表 6: 不确定性优化模型的统一对比

方法	不确定性描述	核心数学结构	典型电力应用
Static RO	$w \in \mathcal{W}$	$g(x, w) \leq 0, \forall w \in \mathcal{W}$	静态安全裕度、规划容量约束
ARO	$w \in \mathcal{W}$ 且允许 $y(w)$	$g(x, y(w), w) \leq 0, \forall w \in \mathcal{W}$	鲁棒 UC、实时备用调度、可调 OPF
DRO	$\mathbb{P} \in \mathcal{D}$	$\sup_{\mathbb{P} \in \mathcal{D}} \mathbb{E}_{\mathbb{P}}[Q(x, w)]$ 或 robust chance constraint	分布鲁棒 OPF、风险限制调度
Data-driven robust SO	ro- 样本 $\{\hat{w}^k\}_{k=1}^N$ 构造 $\mathcal{D}_N$	$d(\mathbb{P}, \hat{\mathbb{P}}_N) \leq \theta_N$	数据驱动 UC、数据驱动 OPF、储能调度

从电力系统运行角度看，四类模型可形成一个自然层级：

$$\boxed{\text{确定性调度}} \rightarrow \boxed{\text{静态安全裕度}} \rightarrow \boxed{\text{可调补救策略}} \rightarrow \boxed{\text{分布鲁棒风险控制}} \rightarrow \boxed{\text{数据驱动安全决策}}. \quad (118)$$

对于高比例新能源系统，单纯确定性模型无法反映预测误差；static RO 能提供强可行性保证但可能过于保守；ARO 能体现调度中的实时调节能力；DRO 能在分布未知时控制期望成本和风险；data-driven robust stochastic program 则进一步把历史样本纳入模型，是连接机器学习预测与优化决策的重要工具。

4.7 小结

本节可以概括为四个关键词：集合、适应性、分布、数据。

- **集合：**静态 RO 用不确定集合 $\mathcal{W}$ 描述所有可能场景，并要求一个固定决策对所有场景可行。
- **适应性：**ARO 把决策分为 here-and-now 与 wait-and-see，允许补救变量随不确定性调整，从而降低保守性。
- **分布：**DRO 把不确定性从变量取值提升到概率分布层面，在歧义集 $\mathcal{D}$ 中优化最坏分布表现。
- **数据：**Data-driven robust stochastic program 利用样本构造歧义集，使模型兼具随机优化的数据利用能力与鲁棒优化的安全保证。

对于电力系统优化研究，理解这些模型的关键不是记住某一个固定公式，而是把握如下逻辑：不确定性越被精细地描述，模型越接近实际运行；但描述越精细，鲁棒对应问题和求解算法也越复杂。因此，实际建模时需要在保守性、可解释性、数据可得性和计算复杂度之间进行权衡。

5 Bilevel Programs

本节参考 Appendix D.3 “Bilevel Programs”，整理双层规划的基本模型、单层等价形式、求解困难与典型特殊情形。双层规划常用于刻画“一个主体先决策，另一个主体随后响应”的顺序决策问题。在电力系统优化中，这类结构非常常见，例如发电商报价与市场出清、零售商定价与用户响应、攻击者与防御者的 interdiction model、上层规划与下层运行调度等。

直观地说，双层规划不是简单地把两个优化问题相加，而是把一个优化问题嵌入另一个优化问题的约束中。上层问题的决策者称为 **leader**（领导者），下层问题的决策者称为 **follower**（跟随者）。在博弈论中，这类问题通常称为 **Stackelberg game**（斯塔克尔伯格博弈）。其基本逻辑是：leader 先给出策略 x ，follower 观察到 x 后选择最优响应 $y(x)$ ，而 leader 在选择 x 时已经预见到 follower 的响应。

5.1 缩略语与符号表

符号/缩写	英文含义	中文解释
x	upper-level decision	上层决策变量，通常由 leader 控制
y	lower-level decision	下层决策变量，通常由 follower 控制
$S(x)$	best-response set	给定 x 时，下层问题的最优响应集合
$F(x, y)$	upper-level objective	上层目标函数
$f(x, y)$	lower-level objective	下层目标函数
$g(x, y)$	inequality constraints	下层不等式约束
$h(x, y)$	equality constraints	下层等式约束
λ, μ	dual variables	下层不等式/等式约束对应的对偶变量
KKT	Karush–Kuhn–Tucker conditions	最优性条件
MPCC	Mathematical Program with Complementarity Constraints	含互补约束的数学规划
MPEC	Mathematical Program with Equilibrium Constraints	含均衡约束的数学规划
EPEC	Equilibrium Program with Equilibrium Constraints	含均衡约束的均衡问题
MILP	Mixed-Integer Linear Programming	混合整数线性规划
CCG	Column-and-Constraint Generation	列与约束生成方法

5.2 基本思想：从顺序决策到双层规划

双层规划的核心在于**决策顺序**。在普通优化问题中，所有变量通常由同一个决策者同时控制；而在双层规划中， x 与 y 分别属于两个决策者。leader 不能直接控制 follower 的变量 y ，但可以通过改变 x 影响下层问题的可行域、目标函数或约束条件，从而间接影响 follower 的最优响应。

一个典型的下层凸优化问题可以写为

$$\begin{aligned} \min_y \quad & f(x, y) \\ \text{s.t.} \quad & g(x, y) \leq 0, \\ & h(x, y) = 0, \end{aligned} \quad (119)$$

其中 x 是上层已经给定的参数, y 是下层决策变量。设该下层问题的最优解集合为

$$S(x) = \arg \min_y \{f(x, y) \mid g(x, y) \leq 0, h(x, y) = 0\}. \quad (120)$$

如果下层问题严格凸, 则 $S(x)$ 通常只有一个元素; 如果不是严格凸, 则可能存在多个最优响应。

在 optimistic setting 下, leader 假设 follower 会在多个下层最优解中选择对 leader 最有利的一个。此时双层规划可写为

$$\begin{aligned} \min_{x, \bar{y}} \quad & F(x, \bar{y}) \\ \text{s.t.} \quad & x \in X, \\ & \bar{y} \in S(x). \end{aligned} \quad (121)$$

这里 $\bar{y}$ 表面上写成上层变量, 但它并不是 leader 可以自由决定的变量, 而必须属于下层最优响应集合 $S(x)$ 。因此, 约束 $\bar{y} \in S(x)$ 才是双层规划区别于普通优化问题的关键。

若采用 pessimistic setting, 则 follower 会在多个最优响应中选择对 leader 最不利的一个。这种设定通常更保守, 也更难求解。工程应用中, 为了得到可处理的模型, 常先采用 optimistic equivalence。

双层规划的基本脉络

1. leader 选择上层变量 x ;
2. follower 在给定 x 后求解下层优化问题;
3. leader 的目标函数 $F(x, y)$ 取决于 follower 的最优响应;
4. 因此, 双层规划的本质是“优化一个包含最优响应映射的优化问题”。

5.3 凸下层问题与 KKT 单层等价

当下层问题是凸优化问题, 并且满足适当的正则性条件时, KKT 条件是下层全局最优的必要且充分条件。此时, 可以用 KKT 条件替代 $\bar{y} \in S(x)$, 把双层规划转化为单层问题。

对下层问题 (119), 构造拉格朗日函数

$$\mathcal{L}(x, y, \lambda, \mu) = f(x, y) + \lambda^\top g(x, y) + \mu^\top h(x, y), \quad (122)$$

其中 $\lambda \geq 0$ 是不等式约束的对偶变量, μ 是等式约束的对偶变量。其 KKT 条件为

$$\begin{aligned} \nabla_y f(x, y) + \nabla_y g(x, y)^\top \lambda + \nabla_y h(x, y)^\top \mu &= 0, \\ g(x, y) &\leq 0, \quad h(x, y) = 0, \\ \lambda &\geq 0, \\ \lambda_i g_i(x, y) &= 0, \quad \forall i. \end{aligned} \quad (123)$$

也可以把互补松弛条件写为

$$0 \leq \lambda \perp -g(x, y) \geq 0, \quad (124)$$

其中 $a \perp b$ 表示 $a^\top b = 0$ ，并且通常要求 $a \geq 0, b \geq 0$ 。

将 (123) 代入 (121)，得到单层 MPCC：

$$\begin{aligned} \min_{x, y, \lambda, \mu} \quad & F(x, y) \\ \text{s.t.} \quad & x \in X, \\ & \nabla_y f(x, y) + \nabla_y g(x, y)^\top \lambda + \nabla_y h(x, y)^\top \mu = 0, \\ & g(x, y) \leq 0, \quad h(x, y) = 0, \\ & 0 \leq \lambda \perp -g(x, y) \geq 0. \end{aligned} \quad (125)$$

这个变换是双层规划中最重要的建模步骤之一。它把“下层必须最优”这一隐式约束，改写成 stationarity、primal feasibility、dual feasibility 与 complementarity 组成的显式约束。

需要注意的是，虽然下层问题本身是凸的，MPCC (125) 通常仍然是非凸的。根本原因是互补条件

$$\lambda_i[-g_i(x, y)] = 0 \quad (126)$$

是两个变量的乘积等式，它会把可行域分裂成多个互斥的“切片”：要么 $\lambda_i = 0$ ，要么 $g_i(x, y) = 0$ 。

5.4 为什么双层规划难求解

双层规划的困难并不只是因为它“多了一层”，而是因为下层最优性条件会引入非凸结构和数值退化结构。

5.4.1 非凸可行域

即使上下层目标函数和约束全部是线性的，KKT 条件中的互补松弛仍然是非凸的。以最简单的线性互补条件为例：

$$0 \leq x \perp y \geq 0. \quad (127)$$

它等价于

$$x \geq 0, \quad y \geq 0, \quad x^\top y = 0. \quad (128)$$

对每个分量而言， x_i 与 y_i 不能同时严格为正。因此可行域不是一个连续光滑的凸集，而是由多个低维面拼接而成。这使得一般 NLP 求解器往往只能得到局部解，难以保证全局最优。

5.4.2 约束规范条件失效

MPCC 的另一个困难是标准 constraint qualification 往往失效。普通 NLP 算法通常依赖 KKT 条件作为局部最优性的判据，但互补约束会导致活跃约束的 Jacobian 行向量线性相关，从而破坏 linear independent constraint qualification。直观地说，当 $x_i > 0$ 时，互补性迫使 $y_i = 0$ ；当 $y_i > 0$ 时，互补性迫使 $x_i = 0$ 。这些被迫激活的约束会让约束系统在交界处缺乏通常意义下的正则性。

因此，直接把 MPCC 交给普通 NLP 求解器并不可靠。即便求解器返回一个 stationary point，也不一定是有效的局部最优解，更不能保证全局最优。

求解困难的核心原因

- 下层最优响应映射 $S(x)$ 通常是非光滑、非凸甚至多值的；
- KKT reformulation 会引入互补约束 $0 \leq a \perp b \geq 0$ ；
- 互补约束造成非凸可行域，并破坏标准约束规范条件；
- 如果下层含整数变量，KKT 与强对偶通常不再适用，问题会进一步复杂化。

5.5 MPCC 的常用处理方法

针对 MPCC 的互补约束，Appendix D.3 总结了几类常用方法。它们的共同思想是：不要直接处理尖锐的互补约束，而是通过松弛、惩罚、平滑或整数化方法，把问题转化为更容易求解的 NLP、MILP 或一系列近似问题。

5.5.1 正则化方法

正则化方法把精确互补条件

$$x \geq 0, \quad y \geq 0, \quad xy = 0 \quad (129)$$

替换为

$$x \geq 0, \quad y \geq 0, \quad xy \leq \varepsilon, \quad (130)$$

其中 $\varepsilon > 0$ 是一个逐渐减小的参数。当 ε 较大时，可行域被放宽，问题更容易求解；当 $\varepsilon \rightarrow 0$ 时，近似模型逐渐逼近原始互补条件。实际计算中通常从较大的 ε 开始，再逐步缩小，否则可能出现数值不稳定。

5.5.2 惩罚方法

惩罚方法将互补约束从约束集合中移除，并把互补违反程度加入目标函数。例如原问题若为

$$\min_z \Phi(z) \quad \text{s.t.} \quad x \geq 0, \quad y \geq 0, \quad xy = 0, \quad (131)$$

可以改写为

$$\min_z \Phi(z) + \frac{1}{\varepsilon} xy \quad \text{s.t.} \quad x \geq 0, \quad y \geq 0. \quad (132)$$

当 ε 越小，惩罚系数 $1/\varepsilon$ 越大，模型越倾向于减少 xy 。该方法的优点是可行域不随迭代改变，上一轮解可以作为下一轮初始点；缺点是惩罚系数过大时容易造成病态问题，而且 NLP 求解器仍可能只得到局部最优。

5.5.3 平滑方法

平滑方法常用 Fischer–Burmeister function 表示互补关系。对标量 x, y ，定义扰动函数

$$\phi(x, y, \varepsilon) = x + y - \sqrt{x^2 + y^2 + \varepsilon}. \quad (133)$$

当 $\varepsilon = 0$ 时， $\phi(x, y, 0) = 0$ 可表示 $x \geq 0, y \geq 0, xy = 0$ ；当 $\varepsilon > 0$ 时，函数变得光滑，更适合嵌入 SQP 等 NLP 算法中。其基本思想是用光滑近似替代非光滑互补结构。

5.5.4 Big-M 线性化方法

若互补条件是线性的，可以引入二进制变量将其转化为 MILP。对于

$$0 \leq y \perp Ax - b \leq 0, \quad (134)$$

可引入 $z \in \{0, 1\}^m$ 与足够大的常数 M ，写成

$$\begin{aligned} 0 &\leq Ax - b \leq Mz, \\ 0 &\leq y \leq M(1 - z). \end{aligned} \quad (135)$$

当 $z_i = 0$ 时， $(Ax - b)_i = 0$ ，而 y_i 可以为正；当 $z_i = 1$ 时， $y_i = 0$ ，而 $(Ax - b)_i$ 可以为正。这样就用整数变量表达了“二者至多一个为正”的逻辑。

Big-M 方法的关键是选择合适的 M 。若 M 太小，可能错误地切掉真实最优解；若 M 太大，MILP 的连续松弛会很弱，求解效率显著下降。因此在实际模型中，应尽量利用变量上下界、物理容量限制或预求解结果给出紧的 M 。

5.6 线性双层规划

线性双层规划是最常见、也最容易进一步变换的一类双层规划。其典型形式为

$$\begin{aligned} \max_x \quad & c^\top x + d^\top y(x) \\ \text{s.t.} \quad & Cx \leq d, \\ & y(x) \in \arg \min_y \left\{ f^\top y \mid By \leq b - Ax \right\}. \end{aligned} \quad (136)$$

这里上层变量 x 会影响下层 LP 的右端项 $b - Ax$ ，即影响 follower 的可行域。leader 预见到下层最优响应 $y(x)$ 后，选择使 $c^\top x + d^\top y(x)$ 最大的策略。

给定 x 后，下层问题是 LP。其 KKT 条件可以写为

$$\begin{aligned} B^\top u &= f, \\ 0 &\geq u \perp Ax + By - b \leq 0, \end{aligned} \quad (137)$$

其中 $u \leq 0$ 是约束 $By \leq b - Ax$ 的对偶变量。用 Big-M 方法线性化互补条件，可得

$$\begin{aligned} -M(1 - z) &\leq u \leq 0, \\ -Mz &\leq Ax + By - b \leq 0, \\ z &\in \{0, 1\}^m. \end{aligned} \quad (138)$$

于是线性双层规划可转化为 MILP：

$$\begin{aligned} \max_{x, y, u, z} \quad & c^\top x + d^\top y \\ \text{s.t.} \quad & Cx \leq d, \\ & B^\top u = f, \\ & -M(1 - z) \leq u \leq 0, \\ & -Mz \leq Ax + By - b \leq 0, \\ & z \in \{0, 1\}^m. \end{aligned} \quad (139)$$

当互补约束数量适中时, (139) 往往可以由现成 MILP 求解器处理。虽然 MILP 在最坏情况下仍是 NP-hard, 但相比直接求解原始双层规划, 这种 reformulation 更系统, 也更容易获得全局最优证书。

另一种处理下层 LP 的方式是使用 primal-dual optimality condition。下层原问题可行、对偶问题可行, 并且满足强对偶时, 有

$$\begin{aligned} B^\top u &= f, \quad u \leq 0, \quad Ax + By \leq b, \\ u^\top (b - Ax) &= f^\top y. \end{aligned} \quad (140)$$

第一行表示原始变量和对偶变量可行, 第二行表示原问题与对偶问题目标值相等。若 x 是连续变量, 则 $u^\top Ax$ 是双线性项, 问题仍然非凸; 若 x 是二进制变量, 则可对 $u_i x_j$ 引入辅助变量进行线性化, 从而得到 MILP。

5.7 Linear Max-Min Problem

线性 max-min 问题是线性双层规划的重要特例。在这类问题中, leader 和 follower 的目标完全相反:

$$\begin{aligned} \max_x \quad & c^\top x + d^\top y(x) \\ \text{s.t.} \quad & x \in X, \\ & y(x) \in \arg \min_y \left\{ c^\top x + d^\top y \mid y \in Y, Ax + By \leq b \right\}. \end{aligned} \quad (141)$$

等价地, 它可写为

$$\max_{x \in X} \min_{y \in Y} \left\{ c^\top x + d^\top y \mid Ax + By \leq b \right\}. \quad (142)$$

这类模型在 robust optimization 中非常常见: x 可以表示系统决策, y 可以表示不利扰动或 worst-case response。

需要特别注意的是, 由于存在耦合约束 $Ax + By \leq b$, 一般不能随意交换 max 与 min 的顺序。leader 先行动意味着它处于更有利的位置; 如果改成 follower 先行动, 问题的均衡结果可能发生变化。这一点与无耦合约束的零和矩阵博弈不同。

为了求解 (142), 可以对内层 LP 使用对偶。若将 Y 合并进耦合约束中, 内层问题的对偶可写为

$$\max_u \left\{ u^\top (b - Ax) \mid B^\top u = d, u \leq 0 \right\}. \quad (143)$$

由 LP 强对偶可得 $d^\top y = u^\top (b - Ax)$, 于是 max-min 问题可转化为

$$\begin{aligned} \max_{x, u} \quad & c^\top x + u^\top b - u^\top Ax \\ \text{s.t.} \quad & x \in X, \\ & B^\top u = d, \quad u \leq 0. \end{aligned} \quad (144)$$

该模型的主要困难变成了双线性项 $u^\top Ax$ 。如果只需要局部高质量解, 可以采用交替优化或 mountain climbing; 如果需要全局解, 则通常需要进行进一步的 MILP 线性化、分支定界或专门的全局优化方法。

5.8 市场模型中的双层结构

双层规划特别适合描述市场中的策略行为: 一方先发布价格或报价, 另一方根据价格或报价进行最优响应。

5.8.1 零售市场问题

在零售市场中，零售商先发布价格 x ，用户根据价格决定购买量 $y(x)$ ，零售商再结合自身采购/生产计划 z 最大化利润。一个抽象模型为

$$\begin{aligned} \max_{x,z} \quad & x^\top D_C y(x) - p^\top D_M z \\ \text{s.t.} \quad & Ax \leq a, \\ & B_1 y(x) + B_2 z \leq b, \end{aligned} \quad (145)$$

下层用户问题为

$$\begin{aligned} \min_y \quad & x^\top D_C y \\ \text{s.t.} \quad & Fy \geq f. \end{aligned} \quad (146)$$

虽然下层是 LP，但上层目标 $x^\top D_C y(x)$ 是双线性的。利用下层 LP 的 KKT 条件

$$D_C^\top x = F^\top u, \quad 0 \leq u \perp Fy - f \geq 0, \quad (147)$$

并结合强对偶

$$x^\top D_C y = f^\top u, \quad (148)$$

可以把原目标中的双线性收入项替换为线性项 $f^\top u$ 。再用 Big-M 线性化互补条件，即可得到 MILP：

$$\begin{aligned} \max_{x,y,u,v,z} \quad & f^\top u - p^\top D_M z \\ \text{s.t.} \quad & Ax \leq a, \quad B_1 y + B_2 z \leq b, \\ & D_C^\top x = F^\top u, \\ & 0 \leq u \leq M(\mathbf{1} - v), \\ & 0 \leq Fy - f \leq Mv, \\ & v \in \{0, 1\}^{N_f}. \end{aligned} \quad (149)$$

这个例子说明：当模型结构合适时，双层规划中的非凸项可以通过对偶关系被精确消去。

5.8.2 批发市场问题

在批发市场中，供应商先提交报价 β ，市场运营机构再通过市场出清模型确定接受量 $p(\beta)$ 与边际价格 $\lambda(\beta)$ 。供应商的上层问题可写为

$$\max_{\beta} \quad \lambda(\beta)^\top p(\beta) - f(p(\beta)), \quad (150)$$

其中 $f(p)$ 是供应商真实生产成本。下层市场出清模型为

$$\begin{aligned} \min_{p,u} \quad & \beta^\top p + c^\top u \\ \text{s.t.} \quad & p^n \leq p \leq p^m, \\ & p + Fu = d, \\ & Au \leq a. \end{aligned} \quad (151)$$

其中平衡约束 $p + Fu = d$ 的对偶变量 λ 给出边际价格。该问题比零售市场更复杂，因为上层目标中直接出现了 $\lambda^\top p$ ，即对偶变量与原始变量的乘积。

通过下层 KKT 条件与强对偶，可以把该项转化为线性表达式：

$$\lambda^\top p = d^\top \lambda + a^\top \xi - c^\top u, \quad (152)$$

其中 ξ 是约束 $Au \leq a$ 对应的对偶变量。因此，批发市场双层问题可以转化为 MPCC：

$$\begin{aligned} \max \quad & d^\top \lambda + a^\top \xi - c^\top u - f(p) \\ \text{s.t.} \quad & \text{下层市场出清问题的 KKT 条件.} \end{aligned} \quad (153)$$

若互补条件可以 Big-M 线性化，且凸成本函数 $f(p)$ 可用分段线性函数近似，则该 MPCC 可进一步转化为 MILP。

5.9 Bilevel Mixed-Integer Program

当下层问题包含整数变量时，双层规划会显著变难。原因是 KKT 条件和强对偶主要适用于凸优化或 LP；对于含整数变量的下层问题，由于可行域非凸，一般不存在简单闭式的最优性条件。因此，bilevel mixed-integer program 通常比 bilevel linear program 更难。

一个典型的 bilevel mixed-integer program 可写为

$$\begin{aligned} \min_{x,y,z} \quad & f^\top x + g^\top y + h^\top z \\ \text{s.t.} \quad & Ax \leq b, \quad x \in \mathbb{R}^{m_c} \times \mathbb{B}^{m_d}, \\ & (y, z) \in \arg \max_{y,z} \left\{ w^\top y + v^\top z \mid Py + Nz \leq r - Kx, \right. \\ & \left. y \in \mathbb{R}^{n_c}, z \in \mathbb{B}^{n_d} \right\}. \end{aligned} \quad (154)$$

其中 z 是下层二进制变量。若下层存在多个最优解，通常仍采用 optimistic assumption，即 follower 选择对 leader 有利的最优解。

为了消除 $\in \arg \max$ 的写法，可以复制下层变量 (y^0, z^0) ，让 leader 用它们表示 follower 的响应：

$$\begin{aligned} \min \quad & f^\top x + g^\top y^0 + h^\top z^0 \\ \text{s.t.} \quad & Ax \leq b, \quad x \in \mathbb{R}^{m_c} \times \mathbb{B}^{m_d}, \\ & Kx + Py^0 + Nz^0 \leq r, \\ & w^\top y^0 + v^\top z^0 \geq \max_{y,z} \left\{ w^\top y + v^\top z \mid Py + Nz \leq r - Kx, \right. \\ & \left. y \in \mathbb{R}^{n_c}, z \in \mathbb{B}^{n_d} \right\}. \end{aligned} \quad (155)$$

这里的主要障碍仍是右侧下层 MILP 的最优值函数。一个思路是枚举下层整数变量 z 的所有可能取值。给定某个 z^j 后，关于连续变量 y 的下层问题变成 LP，可以用 KKT 或强对偶处理。虽然完整枚举通常不可行，但可以采用类似鲁棒优化中 CCG 的方法：先只考虑少数关键 z^j ，求解 master problem；再根据当前 x 求解下层 MILP，发现新的最坏/关键整数策略；随后把对应变量和约束加入 master problem。

其基本流程可概括为：

1. 初始化下界 $LB = -\infty$ 、上界 $UB = +\infty$ ，并选择一个较小的整数策略集合；

2. 在当前策略集合上求解 master problem, 得到候选上层决策 x^* 和下界 LB ;
3. 固定 x^* , 求解完整下层 MILP, 得到 follower 的真实最优响应及其目标值;
4. 若当前响应已经被 master problem 覆盖, 则上下界收敛; 否则加入新的整数策略及其约束, 继续迭代。

由于下层整数变量的可能取值集合是有限的, 该类 CCG 方法理论上可在有限步内终止。但在实际问题中, 算法通常不需要枚举所有整数策略, 因为真正影响最优解的关键策略往往只占很小一部分。

5.10 与电力系统优化的联系

在电力系统中, 双层规划的意义尤其突出, 因为很多问题天然具有“上层策略-下层市场/运行响应”的结构。

- **市场报价:** 发电商或储能运营商在上层选择报价, 系统运营商在下层进行市场出清, 出清结果决定中标电量与电价。
- **需求响应:** 零售商在上层设计电价, 用户在下层根据价格优化用电计划。
- **输电扩建与运行:** 规划者在上层决定线路扩建, 系统在下层执行 OPF 或 UC。
- **攻击-防御模型:** 攻击者在上层选择攻击线路或设备, 系统运营者在下层进行重调度或负荷削减最小化。
- **鲁棒优化中的 max-min 子问题:** 决策者在上层选择运行策略, 不确定性在下层选择最不利场景, 形成线性 max-min 或更复杂的 tri-level 结构。

因此, 学习双层规划并不是为了掌握一种孤立的数学模型, 而是为了理解市场机制、策略行为、不确定性应对和系统运行之间的耦合关系。

5.11 小结

本节的主线可以概括为: 双层规划通过 $y \in S(x)$ 描述 follower 对 leader 决策的最优响应; 当下层是凸优化问题时, 可用 KKT 条件转化为 MPCC; 当下层是 LP 时, 可进一步利用互补线性化或强对偶得到 MILP/NLP reformulation; 当下层包含整数变量时, KKT 与强对偶不再直接适用, 需要枚举、分解或 CCG 等方法处理。

从建模角度看, 双层规划最重要的思想是**把下层优化行为作为上层约束的一部分**。从求解角度看, 其主要困难来自互补约束和下层整数变量。对于电力系统优化而言, 双层规划是连接物理运行、市场出清和策略行为的重要工具, 也是理解 MPEC、EPEC、鲁棒优化和市场均衡模型的基础。

6 参考文献

本节列出本文主要参考的期刊论文与书籍。电力系统优化五十年发展脉络主要参考文献 [1]；电力网络建模、确定性优化、不确定性优化与双层规划等内容主要参考文献 [2]。

- [1] Kaya, A., Conejo, A. J., & Rebennack, S. (2026). Fifty years of power systems optimization. *European Journal of Operational Research*, 329(1), 1–23. <https://doi.org/10.1016/j.ejor.2025.05.022>
- [2] Wei, W., & Wang, J. (2020). *Modeling and Optimization of Interdependent Energy Infrastructures*. Cham: Springer Nature Switzerland AG. <https://doi.org/10.1007/978-3-030-25958-7>